Qué datos tenemos realmente y qué podemos mostrar en el gemelo digital

Cerebro Helsinki · Taller de Datos · Gestión y Gobernanza de Datos (EAFIT 2026-2)

Informe del 26 de octubre de 2026. Base: el catálogo unificado de 63 fuentes, los datos que hay en disco y la interfaz actual del repositorio. Las pruebas de las fuentes son del 21 y del 28 de septiembre de 2026.

Resumen corto

Hoy el sistema tiene **datos reales de solo tres cosas**: 4 polígonos municipales, 6.027 paradas y un feed de vehículos en vivo. El visor 3D es un iframe externo, sin datos nuestros. Todo lo demás está catalogado y probado (63 fuentes en `docs/catalogo-fuentes.md`), pero **no hay ninguna fuente ingerida** más allá de esas tres. Tampoco existen `lago/` ni `verificar.py`.

1. Lo que tenemos de verdad

Dato	Qué hay	Vigencia / licencia
Límites municipales	4 polígonos (Helsinki 091, Espoo 049, Vantaa 092, Kauniainen 235), generalizados a 1:1.000.000. No sirven para barrios.	2025 · CC BY 4.0
Paradas HSL	6.027 puntos de abordaje. Helsinki 2.601, Espoo 1.787, Vantaa 1.560, Kauniainen 79. Campos: `stop_id`, `stop_code`, nombre, zona tarifaria, accesibilidad (`wheelchair_boarding`), municipio.	Feed del 2026-09-18 al 2026-11-16 · CC BY 4.0
Vehículos en vivo	Unos 360 vehículos con posición, vía el proxy GTFS-RT. Es un sondeo del 2026-09-20; en producción no se ha ejercitado.	CC BY 4.0
Visor 3D de Helsinki	Solo un iframe. Dio timeout a los 30 s desde Colombia, en dos fases distintas.	CC BY 4.0
Teselas OSM	Solo fondo del mapa; ninguna cifra sale de ahí.	ODbL

Hay más en `data/raw/hsl_stops.txt` de lo que muestra la UI. El ETL descarta `vehicle_type` y la UI no usa la zona ni la accesibilidad. Los conté sobre las 6.027 paradas. Son números calculados para este informe, no del lago, así que no se pueden publicar hasta que salgan del ETL:

- **Modos:** 5.513 bus, 358 tranvía, 96 tren de cercanías, 58 metro y 2 ferry.
- **Zonas tarifarias:** A 952, B 3.015, C 2.059 y D 1.
- **Accesibilidad según el feed:** 743 accesibles, 2.744 no accesibles y 2.540 sin información. El 46 % de «no accesible» es alto. Hay que contrastarlo con la documentación de HSL antes de afirmar nada.

2. Catalogado y probado, pero sin ingerir

Resultados reales de las pruebas del 21 y el 28 de septiembre. El semáforo mide permiso (licencia y datos de personas): verde se puede usar, amarillo se puede usar con una condición escrita, rojo no se publica tal cual.

Tema	Fuente	Qué trae	Semáforo
Población	StatFin 11ra	Helsinki 694.392, Espoo 325.716, Vantaa 252.956, Kauniainen 10.318 (31-12-2025)	Verde
	Paavo 2026	167 áreas postales: densidad, ingreso, educación, tenencia de vivienda, empleos	Verde
	Rejillas de población (1 km Stat. Finland, 250 m HSY)	749 y 5.826 celdas. Los centinelas `-1` y 99 son datos protegidos.	Verde
Vivienda	StatFin 13mu	Precio de vivienda usada por código postal. Solo se consultaron metadatos.	Verde

Tema	Fuente	Qué trae	Semáforo
Edificios	HSY registro de edificios `pks_rakennukset_paivittyva`	154.154 edificios con pisos, año y calefacción. Solo agregados, porque con la dirección identifica un hogar.	Amarillo
	Overture	258.743 edificios en el bbox, 66 % con altura. Licencia ODbL.	Amarillo
	Rejilla de edificación HSY	8.663 celdas	Verde
Energía	HSY consumo (XLSX)	Energía por sector y municipio, hasta 2025. Los bloques traen unidades distintas.	Verde
	Nuuka	1.810 inmuebles públicos con consumo medido	Verde
	Potencial solar HSY	154.586 polígonos. Es un modelo de 2021, no una medición.	Verde
Ambiente	HSY calidad del aire	13 estaciones, horaria	Verde
	FMI	Clima observado (Kaisaniemi) y una segunda vía para el aire	Verde
	Cobertura del suelo HSY	Verde urbano y superficie impermeable, 2016–2024	Verde
Movilidad	Digitraffic	518 estaciones de tráfico (nacional, solo vías estatales) y 563 de trenes	Verde
	Estaciones de bici HSL	200 estaciones. Solo ubicación y capacidad.	Verde
Servicios	Service Map v2	21.514 unidades de servicio. Hay que descartar `contact_person`, `email` y `phone`.	Amarillo
	Linked Events y PTV	407.244 eventos y los canales de servicio de Helsinki	Amarillo
Economía	PRH/YTJ	89.936 empresas con location=Helsinki. Solo conteos; los registros individuales son rojo.	Rojo / amarillo

Lo que no existe o está caído (hay que declararlo como hueco)

- Altura oficial por edificio: el WFS de Helsinki dio timeout.
- Distritos oficiales de Helsinki (`kartta.hel.fi`, timeout).
- Energía por edificio: solo el 0,5 % tiene clase energética.
- Disponibilidad de bicicletas en vivo (Digitransit pide llave).
- Decisiones municipales (OpenAhjo).
- Áreas protegidas y calidad de aguas (SYKE devuelve un 200 con error dentro).
- Alquiler de corta estancia (Inside Airbnb no cubre Helsinki).
- Google Open Buildings no cubre Finlandia.

3. Qué podríamos mostrar, por secciones

Propongo mantener las pestañas actuales y llenarlas por niveles de esfuerzo.

Nivel A: ya, sin ingestar nada nuevo

- **Live Mobility.** Ya funciona. Se le puede añadir el modo (`vehicle_type`) y la zona tarifaria con un cambio chico en el ETL.
- **Overview.** Paradas por municipio y por modo. Si se añade el denominador de StatFin, también paradas por 1.000 habitantes.
- **Accesibilidad de paradas.** Mostrar el porcentaje «sin información» de forma visible, no solo el «accesible».

Nivel B: una ingesta por fuente, pocas horas cada una

- **Gemelo digital.** Capa 3D local de edificios (extrusión en MapLibre) con Overture. Hay que recortar al polígono de los municipios y revisar la altura media de aprox. 5 m. Cumple la obligación ODbL. Es la salida real si el

iframe de `kartta.hel.fi` no carga en clase.

- **Densidad y perfil socioeconómico.** Mapa coroplético de Paavo (167 áreas) con densidad, ingreso medio y educación. Cruzado con las paradas, responde «quién queda cerca del transporte».
- **Climate & Energy.** Hoy está vacía y puede salir ya con calidad del aire en vivo (HSY y FMI, dos vías para el mismo dato), clima de Kaisaniemi, consumo de energía por sector y municipio de HSY (leyendo la unidad de cada bloque) y Nuuka para edificios públicos.
- **Services & Access.** Service Map con id, nombre, servicio, municipio y punto, sin contactos. Una métrica derivada es servicios cercanos a cada parada.

Nivel C: requieren decidir o resolver algo antes

- **Pisos, año y calefacción por zona.** Con HSY edificios solo en agregados por rejilla o código postal, nunca polígono con dirección.
- **Empleo.** La rejilla de HSY se publica por niveles, porque una celda con 1 o 2 empleos puede señalar a un solo empleador.
- **Innovation & Research.** El catálogo no tiene ninguna fuente de investigación (OpenAlex y Crossref no están sondeados). Lo defendible hoy es conteos de empresas por sector (PRH) y educación (Vipunen, 47 conjuntos, licencia por reconfirmar). Si no se quiere eso, la pestaña debe seguir como «hueco declarado».

Qué no mostrar, y decirlo en pantalla

Direcciones por edificio, registros de empresas individuales, reportes Open311, contactos de Service Map, y cualquier mapa de eficiencia energética por edificio.

4. Cuatro problemas que encontré en el repo

1. **El registro de la UI está desactualizado.** `public/data/sources.json` tiene 7 fuentes y el catálogo tiene 63. Por ejemplo, la UI muestra Service Map como «candidate / licencia desconocida», pero el catálogo lo probó OK (21.514 unidades) y dice CC BY 4.0.
2. **Las 5 «integradas» inflan la cifra.** Esas 5 incluyen las teselas OSM (solo fondo) y un iframe. `update-report.json` marca el modelo 3D como `integrated` y OSM edificios como `failed`.
3. **«Probada OK» suele ser poco.** Para la mayoría solo se verificó un HTTP 200 y un conteo, no que los campos estén completos. Los nombres de campos de Paavo salen de la ficha; hay que confirmarlos al ingerir.
4. **Las cifras de Overture no se pueden publicar todavía.** La altura media de aprox. 5 m es sospechosa y la distribución sigue sin revisar.

> **Recomendación.** Empezar por **Paavo más el cruce con paradas**. Es la capa de mayor valor (responde la pregunta de quién queda cerca del transporte), es verde y tiene código territorial para cruzar. Y es la que crea el primer contrato de datos y el primer `verificar.py` real del lago. Después, aire y clima para llenar Climate & Energy, y Overture para el 3D local.

Fuentes de este informe

- `docs/catalogo-fuentes.md` y `docs/catalogo/fuentes.json`: índice unificado de 63 fuentes (5 integradas, 25 candidatas, 8 condicionadas, 6 caídas, 17 descartadas, 2 no existen).
- `catalogo/*.md` y `data/metadata/candidate_probes.json`: fichas detalladas y resultados de las pruebas del 2026-09-21.
- `public/data/sources.json`, `public/data/update-report.json`, `data/raw/hsl_stops.txt` y `public/data/*.geojson`: lo que realmente hay en disco.
- `src/main.jsx`: secciones y capas de la interfaz actual.

Las cifras de la sección 1 sobre modos, zonas y accesibilidad se calcularon para este informe a partir de los archivos en disco; no vienen del ETL y por eso no deben aparecer en la UI sin pasar por el lago y por la verificación.